

TECNOLÓGICO
NACIONAL DE MÉXICO

TECNOLOGICO DE COLIMA

ALUMNO:

Kevin Gilberto Borjas avalos

MATERIA:

Ingeniería de datos

DOCENTE:

Armando Roman Gallardo Heredia

FECHA:

25/10/2026

PROYECTO PIPELINE

INTRODUCCION

FASE 1

1. ¿En qué consiste la Fase 1?

Es el diagnóstico de calidad inicial: una radiografía de los datos crudos antes de tocar nada. Sirve para saber con qué problemas llegamos y para tener un punto de comparación. Después, en el reporte “antes/después” del Ingeniero 1 osea yo, mostrará cuánto mejoró la calidad.

Mide tres cosas, como pide la guía:

- Completitud: el % de nulos por columna.
- Unicidad: los duplicados exactos, y también los duplicados por llave (por ejemplo, el mismo id_transaccion repetido).
- Tipos inferidos: el dtype que pandas asigna a cada columna.

RESULTAD:

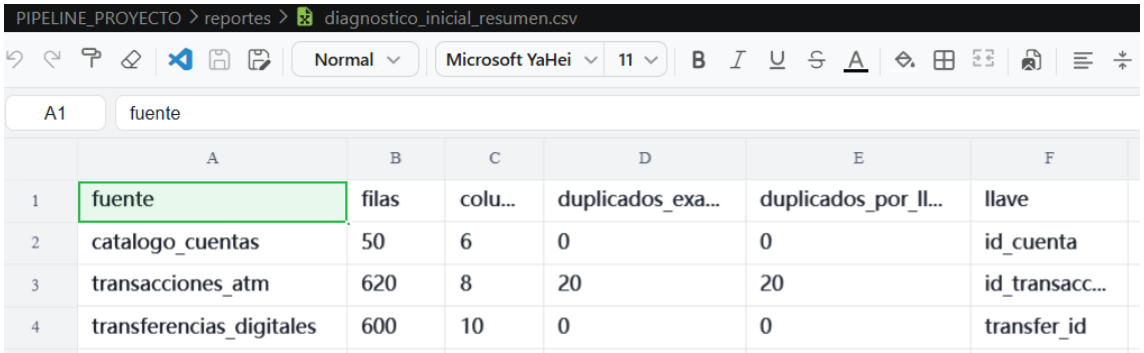
```
PS C:\Users\Colibecas\Desktop\Tecnologico\practica-sensores\PIPELINE_PROYECTO> python pipeline_etl.py
Duplicados por llave 'transfer_id': 0

Completitud y tipos por columna:
                    dtype  nulos  pct_nulos  completitud_pct  valores_unicos
columna
transfer_id           str      0       0.00           100.00             600
timestamp          object      0       0.00           100.00             598
account_id            str      0       0.00           100.00              79
amount            float64      0       0.00           100.00             600
currency              str      0       0.00           100.00               2
beneficiary_clabe     str      0       0.00           100.00             555
notification_email    str      8       1.33            98.67             419
concept               str      0       0.00           100.00               6
status                str      0       0.00           100.00               5
platform              str      0       0.00           100.00               4

Reportes guardados en la carpeta 'reportes/'.
```

Ademas creamos 2 carpetas mas

diagnostico_inicial_resumen.csv



	A	B	C	D	E	F
1	fuente	filas	colu...	duplicados_exa...	duplicados_por_ll...	llave
2	catalogo_cuentas	50	6	0	0	id_cuenta
3	transacciones_atm	620	8	20	20	id_transacc...
4	transferencias_digitales	600	10	0	0	transfer_id

diagnostico_inicial_columnas.csv

	A	B	C	D	E	F	G
1	fuente	columna	dtype	nulos	pct_n...	completitud...	valores_uni...
2	catalogo_cuen...	id_cuenta	str	0	0.0	100.0	50
3	catalogo_cuen...	titular	str	0	0.0	100.0	49
4	catalogo_cuen...	tipo_cuenta	str	0	0.0	100.0	5
5	catalogo_cuen...	limite_credito_...	float64	0	0.0	100.0	5
6	catalogo_cuen...	fecha_apertura	str	0	0.0	100.0	50
7	catalogo_cuen...	estado_cuenta	str	0	0.0	100.0	3
8	transacciones_...	id_transaccion	str	0	0.0	100.0	600
9	transacciones_...	fecha_hora	str	0	0.0	100.0	600
10	transacciones_...	id_cuenta	str	0	0.0	100.0	82
11	transacciones_...	tipo_operacion	str	0	0.0	100.0	4
12	transacciones_...	monto_mxn	float64	27	4.35	95.65	14
13	transacciones_...	id_cajero	str	44	7.1	92.9	5
14	transacciones_...	resultado	str	0	0.0	100.0	4
15	transacciones_...	comision_aplica...	float64	0	0.0	100.0	4
16	transferencias_...	transfer_id	str	0	0.0	100.0	600
17	transferencias_...	timestamp	object	0	0.0	100.0	598
18	transferencias_...	account_id	str	0	0.0	100.0	79
19	transferencias_...	amount	float64	0	0.0	100.0	600
20	transferencias_...	currency	str	0	0.0	100.0	2
21	transferencias_...	beneficiary_clabe	str	0	0.0	100.0	555
22	transferencias_...	notification_em...	str	8	1.33	98.67	419
23	transferencias_...	concept	str	0	0.0	100.0	6
24	transferencias_...	status	str	0	0.0	100.0	5
25	transferencias_...	platform	str	0	0.0	100.0	4

FASE 2

¿En qué consiste la Fase 2?

Es el manejo de faltantes e imputación: decidir qué hacer con los valores vacíos sin inventar datos ni borrar filas de más. Aquí se hace lo siguiente:

1. Hacer visibles los vacíos disfrazados. Los "" y los N/A no cuentan como nulos para pandas. Al normalizarlos aparece un hallazgo: notification_email tiene 16 vacíos reales, no 8. Los otros 8 eran cadenas vacías.

2. Eliminar los duplicados del ATM. Los 20 reintentos de cajero se borran primero para que no distorsionen las medianas.
3. Clasificar los faltantes (MCAR o MAR). El código imprime el % de nulos por categoría. Si el faltante no depende de otra variable, es MCAR (completamente al azar).
4. Imputar según el tipo de variable:
    - monto_mxn (numérica muy sesgada) se imputa con la mediana por tipo_operacion. La media no sirve: está inflada por un monto de 3,500,000 y es 9,527 contra una mediana de 1,500.
    - id_cajero y notification_email (categóricas) reciben etiquetas controladas: CAJERO_DESCONOCIDO y ANONIMO.
5. Recalcular lo recalculable. En estos datos no hay un par como cantidad * precio_unitario. La regla equivalente es que una CONSULTA_SALDO no mueve dinero, así que su monto es 0.

Los emails malformados (correo@@sinformato, invalido.com) no se tocan aquí. Se quedan para que Pydantic los mande a cuarentena en la Fase 6. Lo mismo pasa con las CLABEs de 5 dígitos.

RESULTADO:

```
======================================================================
FASE 2: MANEJO DE FALTANTES E IMPUTACIÓN
======================================================================

Nulos REALES tras normalizar vacíos disfrazados:
  atm.monto_mxn: 27 | atm.id_cajero: 44 | digitales.notification_email: 16
[ATM] Duplicados exactos eliminados: 20 (620 -> 600 filas)

--- Evidencia MCAR/MAR: % nulos de monto_mxn por tipo_operacion ---
                nulos  total  pct_nulos
tipo_operacion
CONSULTA_SALDO      0     97       0.00
DEPOSITO            7    127       5.51
PAGO_SERVICIOS      4    114       3.51
RETIRO             16    262       6.11

--- % nulos de monto_mxn por resultado ---
                nulos  total  pct_nulos
resultado
EXITOSA            12    298       4.03
FALLO_CONEXION      4    117       3.42
FALLO_FONDOS        6    104       5.77
exitosa             5     81       6.17

--- % nulos de id_cajero por tipo_operacion ---
                nulos  total  pct_nulos
tipo_operacion
CONSULTA_SALDO     10     97      10.31
DEPOSITO           10    127       7.87
PAGO_SERVICIOS      8    114       7.02
RETIRO             14    262       5.34

--- % nulos de notification_email por platform ---
                 nulos  total  pct_nulos
platform
API Empresarial      3    166       1.81
App Android          5    145       3.45
App iOS              5    139       3.60
```

```
--- % nulos de notification_email por platform ---
                nulos  total  pct_nulos
platform
API Empresarial     3    166       1.81
App Android         5    145       3.45
App iOS             5    139       3.60
Web Banking         3    150       2.00

--- Por qué mediana y no media (monto_mxn) ---
  Media   : 9,527.40
  Mediana : 1,500.00
  Máximo  : 3,500,000.00
  Asimetría (skew): 23.91  (>1 = muy sesgada a la derecha)

--- Comparativo antes / después ---
                  nulos_antes  nulos_despues                                    metodo
columna
monto_mxn                  27             0  Mediana por tipo_operacion (CONSULTA_SALDO = 0)
id_cajero                  42             0                  Etiqueta 'CAJERO_DESCONOCIDO'
notification_email         16             0                           Etiqueta 'ANONIMO'
```

FASE 3

1. ¿En qué consiste la Fase 3?

Es el tratamiento de outliers con IQR y capping. Un outlier es un valor tan extremo que distorsiona las estadísticas, como el retiro de 3,500,000 que viste en la Fase 2. En lugar de borrar esas filas, se recortan al umbral límite. A esto se le llama *winsorizing*.

1. Calcular el IQR. Es Q3 - Q1, y los umbrales son Q1 - 1.5·IQR y Q3 + 1.5·IQR. Todo lo que quede fuera se recorta al umbral.
2. Eliminar solo lo imposible. Se borran únicamente los montos <= 0 en operaciones que mueven dinero. La CONSULTA_SALDO con monto 0 es legítima y no se toca.
3. Elegir bien sobre qué se calcula el IQR. Hay dos decisiones aquí:
    - ATM: por tipo de operación y sin CONSULTA_SALDO. Sus ceros no son datos reales y bajarían los cuartiles. Si calculara el IQR global, recortaría a los 48 depósitos y pagos legítimos de 12,000, que son un valor normal y frecuente.
    - Digitales: por moneda. MXN y USD tienen escalas distintas, y la conversión a pesos es la Fase 4.
4. Dejar evidencia. Cada valor recortado queda registrado con su valor original y su valor recortado.

RESULTADO:

```
FASE 3: TRATAMIENTO DE OUTLIERS CON IQR (CAPPING)
================================================================
[ATM] Registros con monto imposible (<= 0) eliminados: 0
[DIGITALES] Registros con amount imposible (<= 0) eliminados: 0

--- Umbrales IQR (factor 1.5) por grupo ---
  columna          grupo   n       Q1       Q3      IQR  umbral_inferior  umbral_superior  outliers
monto_mxn       DEPOSITO 127  1500.00  8000.00  6500.00         -8250.00         17750.00         0
monto_mxn PAGO_SERVICIOS 114  1500.00  8000.00  6500.00         -8250.00         17750.00         0
monto_mxn         RETIRO 262   500.00  5000.00  4500.00         -6250.00         11750.00         1
   amount            MXN 466 10000.96 26267.60 16266.64        -14399.01         50667.57        15
   amount            USD 134 11413.89 26838.64 15424.75        -11723.23         49975.76         3

Total de valores recortados (winsorizing): 19
   fuente_llave   columna  grupo  valor_original  valor_capeado
   ATM-TX-00416 monto_mxn RETIRO       3500000.0       11750.00
SPEI-2026-00022    amount    MXN       5141233.5       50667.57
SPEI-2026-00101    amount    MXN       1325872.5       50667.57
SPEI-2026-00109    amount    MXN       5240100.0       50667.57
SPEI-2026-00142    amount    MXN       5001225.0       50667.57
SPEI-2026-00186    amount    MXN       4604904.0       50667.57
SPEI-2026-00331    amount    MXN       1361187.0       50667.57
SPEI-2026-00376    amount    MXN       2072223.0       50667.57
SPEI-2026-00393    amount    MXN        199902.0       50667.57
SPEI-2026-00421    amount    MXN       1456236.0       50667.57
SPEI-2026-00454    amount    MXN       2806686.0       50667.57
SPEI-2026-00460    amount    MXN       3179809.5       50667.57
SPEI-2026-00475    amount    MXN       2754598.5       50667.57
SPEI-2026-00500    amount    MXN        370996.5       50667.57
SPEI-2026-00568    amount    MXN       2581932.0       50667.57
SPEI-2026-00574    amount    MXN       2745655.5       50667.57
SPEI-2026-00009    amount    USD       4141401.0       49975.76
SPEI-2026-00019    amount    USD       2893386.0       49975.76
SPEI-2026-00042    amount    USD        707211.0       49975.76
```

```
--- Comparativo estadístico antes / después ---
           atm_monto_antes  atm_monto_despues  dig_amount_antes  dig_amount_despues
media              9225.33            3411.58          98261.81            18804.11
mediana            1500.00            1500.00          18448.76            18448.76
desv_est         142797.13            3753.54         533615.81            11106.66
minimo                0.00               0.00             73.62               73.62
maximo          3500000.00           12000.00        5240100.00            50667.57
asimetria            24.47               1.03              7.47                0.46

Reportes guardados: outliers_limites_iqr.csv, outliers_detalle_recortes.csv, outliers_antes_despues.csv
Filas finales -> ATM: 600 | Digitales: 600 (no se perdió ninguna por outliers)
```

FASE 4

¿En qué consiste la Fase 4?

Es la integración y unificación. Hasta ahora teníamos tres fuentes con formatos distintos. Esta fase las convierte en una sola tabla coherente y las contrasta con el catálogo de cuentas:

1. Fechas a ISO (YYYY-MM-DD). Las fechas llegan en 5 formatos distintos. En el ATM hay tres: 2026/09/15 8:45:00, 2026-10-12 22:22:00 y 12/09/2026 13:26. En el JSON hay texto ISO con zona horaria y números epoch. Todo se lleva a hora local de Colima (UTC-6).
2. Conversión de moneda. Los importes en USD se multiplican por 19.50 para llevarlos a MXN. Se conservan el monto y la moneda originales.
3. Fusión de ATM y transferencias digitales en una sola tabla de 1,200 filas, con columnas comunes. Los textos se normalizan, por ejemplo exitosa y EXITOSA pasan a EXITOSA.
4. Cruce con el catálogo maestro. Las transacciones cuya cuenta no existe en el catálogo se marcan como huérfanas. No se borran: se marcan para que la Fase 6 las desvíe a cuarentena con su motivo.

Sobre la ambigüedad de fechas como 12/09/2026: se interpreta como DD/MM/AAAA. En el ATM, 77 fechas de ese tipo tienen un primer número mayor a 12 y ninguna tiene un segundo número mayor a 12, así que no puede ser MM/DD.

RESULTADO:

```
FASE 4: INTEGRACIÓN, UNIFICACIÓN Y HUÉRFANOS
================================================================

--- Formatos de fecha detectados (antes) ---
ATM.fecha_hora:
fecha_hora
9999/99/99 99:99:99    169
9999-99-99 99:99:99    154
99/99/9999 99:99       147
99/99/9999 9:99         46
9999/99/99 9:99:99      42
9999-99-99 9:99:99      42

DIGITALES.timestamp:
timestamp
str: 9999-99-99T99:99:99-99:99    405
int: 9999999999                   195

Fechas que no se pudieron interpretar: 0
Rango de fechas homologado: 2026-09-01 a 2026-10-16
Importes convertidos de USD a MXN (x 19.5): 134
 id_transaccion  monto_original moneda_original  monto_mxn
SPEI-2026-00003        28312.37            USD  552091.22
SPEI-2026-00004        24203.36            USD  471965.52
SPEI-2026-00007         7353.49            USD  143393.06

--- Transacciones con cuenta huérfana (no existe en el catálogo) ---
         huerfanas  total  pct_huerfanas
canal
ATM             32    600          5.33
DIGITAL         29    600          4.83
Total huérfanas: 61 de 1200 (5.08%) -> se desviarán a cuarentena en la Fase 6
Ejemplos de cuentas huérfanas: CTA-8997, CTA-8207, CTA-9193, CTA-8155, CTA-9747

Tabla integrada: 1200 filas x 23 columnas
canal
ATM        600
DIGITAL    600
```

FASE 5

Es la transformación de la variable de importe, en dos pasos sobre monto_mxn:

1. Escalamiento Min-Max. Lleva los montos al rango [0, 1] con (x - min) / (max - min). El monto mínimo (0) pasa a 0.0 y el máximo pasa a 1.0. Se guarda en la columna nueva monto_mxn_norm.
2. Discretización en 3 segmentos (Bajo, Medio, Alto). Se usan terciles, es decir, cortes en los percentiles 33.3 y 66.7. Se eligió este método porque cada segmento queda con la misma cantidad de registros (400 de 1,200) y no hay que inventar umbrales arbitrarios. Es una justificación fácil de defender en tu reporte. El resultado va en la columna nueva segmento_monto.

RESULTADO:

```
FASE 5: TRANSFORMACIÓN, DISCRETIZACIÓN Y ESCALAMIENTO
================================================================

--- Escalamiento Min-Max de monto_mxn ---
  Mínimo : 0.00  -> 0.0
  Máximo : 974,527.25  -> 1.0
  Rango resultante: [0.0, 1.0]

--- Discretización por terciles (Bajo / Medio / Alto) ---
  Bajo  : monto_mxn <= 3,048.73
  Medio : 3,048.73 < monto_mxn <= 16,435.73
  Alto  : monto_mxn >  16,435.73

Registros por segmento:
               registros  monto_min  monto_max
segmento_monto
Bajo                 400       0.00    3006.08
Medio                400    3070.05   16420.14
Alto                 400   16466.90  974527.25

Segmentos por canal y moneda original:
segmento_monto           Bajo  Medio  Alto
canal   moneda_original
ATM     MXN               361    239     0
DIGITAL MXN                37    160   269
        USD                 2      1   131

Muestra (un registro de cada segmento):
 id_transaccion   canal  monto_mxn  monto_mxn_norm segmento_monto
   ATM-TX-00339     ATM     500.00        0.000513          Bajo
   ATM-TX-00178     ATM    8000.00        0.008209         Medio
SPEI-2026-00236 DIGITAL   30623.83        0.031424          Alto

Reportes guardados: transformacion_parametros.csv, segmentos_por_canal.csv, transacciones_transformadas.csv
Tabla final de la fase: 1200 filas x 25 columnas
```

FASE 6

¿En qué consiste la Fase 6?

Es la validación con Pydantic y la zona de cuarentena. Hasta ahora limpiaste, integraste y transformaste, pero nada garantiza que cada fila cumpla las reglas del negocio. Esta fase pone una “aduana” antes de la base de datos:

1. Esquema estricto (TransaccionLimpia). Define el tipo y las restricciones de cada columna. Los montos no pueden ser negativos, el estado debe ser uno de los 7 conocidos y monto_mxn_norm debe estar entre 0 y 1.
2. Validadores personalizados (@field_validator). Revisan las reglas que no cubren los tipos:
    - la CLABE debe tener 18 dígitos (hay 46 de 5 dígitos),
    - el email debe ser válido o ANONIMO (hay 30 malformados),
    - la cuenta debe existir en el catálogo (61 huérfanas).
3. Reglas entre campos (@model_validator). Comprueban que monto_mxn coincida con el monto original por el tipo de cambio, que un ATM traiga cajero y que una transferencia traiga CLABE y correo.
4. Cuarentena sin detener el lote. Cada fila se valida dentro de try ... except ValidationError. Si falla, se desvía a cuarentena con la columna motivo_rechazo_cuarentena, que junta todos los motivos de esa fila. Hay además un except Exception final para que nada tumbe el pipeline (lo que pide el criterio de resiliencia de la rúbrica).

Los registros válidos quedan listos para cargarse a la base de datos.

RESULTADOS:

```
FASE 6: VALIDACIÓN CON PYDANTIC Y ZONA DE CUARENTENA
================================================================

Registros recibidos      : 1200
Registros válidos        : 1072
Registros en cuarentena  : 128
Control de integridad    : 1072 + 128 = 1200 (debe ser 1200)

--- Motivos de rechazo (un registro puede tener varios) ---
          motivo  registros
 CUENTA_HUERFANA         61
  CLABE_INVALIDA         46
EMAIL_MALFORMADO         30
Registros con más de un motivo: 8

--- Cuarentena por canal ---
canal
DIGITAL    96
ATM        32

--- Muestra de cuarentena ---
id_transaccion canal id_cuenta                                  motivo_rechazo_cuarentena
  ATM-TX-00009   ATM  CTA-8997 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00013   ATM  CTA-8207 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00027   ATM  CTA-9193 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00041   ATM  CTA-8155 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00048   ATM  CTA-9747 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00077   ATM  CTA-9411 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro

Reportes guardados: registros_validos.csv, cuarentena_errores.csv, cuarentena_resumen.csv
```

FASE 7

¿En qué consiste la Fase 7?

Es la carga transaccional a la base de datos. Hasta ahora limpiamos, integramos, transformamos y validamos, pero todo vive en memoria (DataFrames y listas). Esta fase lo vuelve permanente y auditable: lo que pasó la “aduana” de la Fase 6 se guarda en SQLite (o PostgreSQL), separado de lo que fue rechazado.

1. Esquema de tablas. Se crean las dos tablas obligatorias con CREATE TABLE IF NOT EXISTS:
    - transacciones_limpias: los registros que cumplieron el esquema TransaccionLimpia. Usa una llave primaria (por ejemplo id_transaccion) y tipos acordes a cada columna.
    - cuarentena_errores: los registros rechazados, con sus datos originales y la columna motivo_rechazo_cuarentena para saber por qué cayeron.
2. Conexión y carga. Se abre la conexión (sqlite3.connect(...)) y se insertan los datos por lotes, con executemany() o DataFrame.to_sql(). Así se evita insertar fila por fila.
3. Transacciones seguras (commit / rollback). La carga se ejecuta dentro de un bloque try ... except:
    - Si todo sale bien, se hace conn.commit() y los cambios quedan guardados.

- Si algo falla a la mitad (error de integridad, disco, llave duplicada), se hace conn.rollback() y la base queda como estaba, sin cargas parciales.
- Un finally cierra la conexión (conn.close()) pase lo que pase.

4. Verificación de integridad. Después de cargar se comprueba que las cuentas cuadren: filas leídas = filas en transacciones_limpias + filas en cuarentena_errores. Eso demuestra que no se perdió ni se duplicó ningún registro. También conviene hacer un SELECT COUNT(*) por tabla y revisar unas filas de muestra para confirmar que las tablas quedaron "íntegras y legibles", como pide la rúbrica.
5. Pruebas de estrés. Esto corresponde al Ingeniero/a 3. Se inyectan datos corruptos a propósito (montos negativos, CLABEs cortas, cuentas huérfanas) y se comprueba que el pipeline no se cae y que los registros malos terminan en cuarentena. Es la evidencia del criterio de resiliencia de la rúbrica.

RESULTADO:

```
FASE 7: CARGA TRANSACCIONAL A BASE DE DATOS (SQLite)
======================================================================

Base de datos           : pipeline_fintech.db
Transacción             : COMMIT realizado con éxito
transacciones_limpias   : 1072 filas
cuarentena_errores      : 128 filas
Control de integridad   : 1072 + 128 = 1200 (debe ser 1200)
PRAGMA integrity_check  : ok

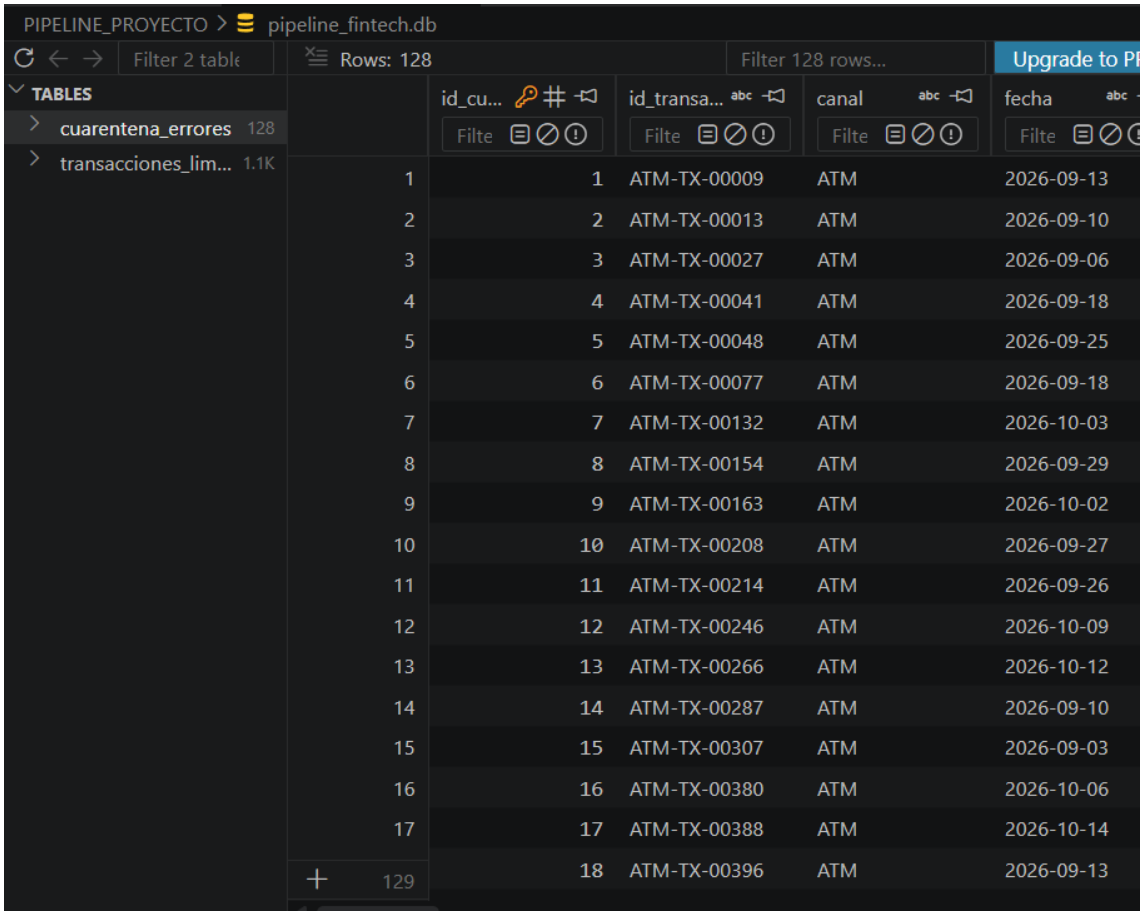
--- transacciones_limpias por canal ---
  canal  registros  monto_total_mxn
    ATM        568       1948050.00
DIGITAL        504      50227558.47

--- transacciones_limpias por segmento ---
segmento_monto  registros
          Bajo        371
         Medio        366
          Alto        335

--- cuarentena_errores por canal ---
  canal  registros
    ATM         32
DIGITAL         96

--- Muestra de cuarentena_errores (leída desde la BD) ---
id_transaccion canal id_cuenta                                    motivo_rechazo_cuarentena
  ATM-TX-00009   ATM  CTA-8997 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00013   ATM  CTA-8207 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00027   ATM  CTA-9193 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00041   ATM  CTA-8155 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro
  ATM-TX-00048   ATM  CTA-9747 CUENTA_HUERFANA: la cuenta no existe en el catálogo maestro

Reporte guardado: carga_bd_resumen.csv | BD: pipeline_fintech.db
```



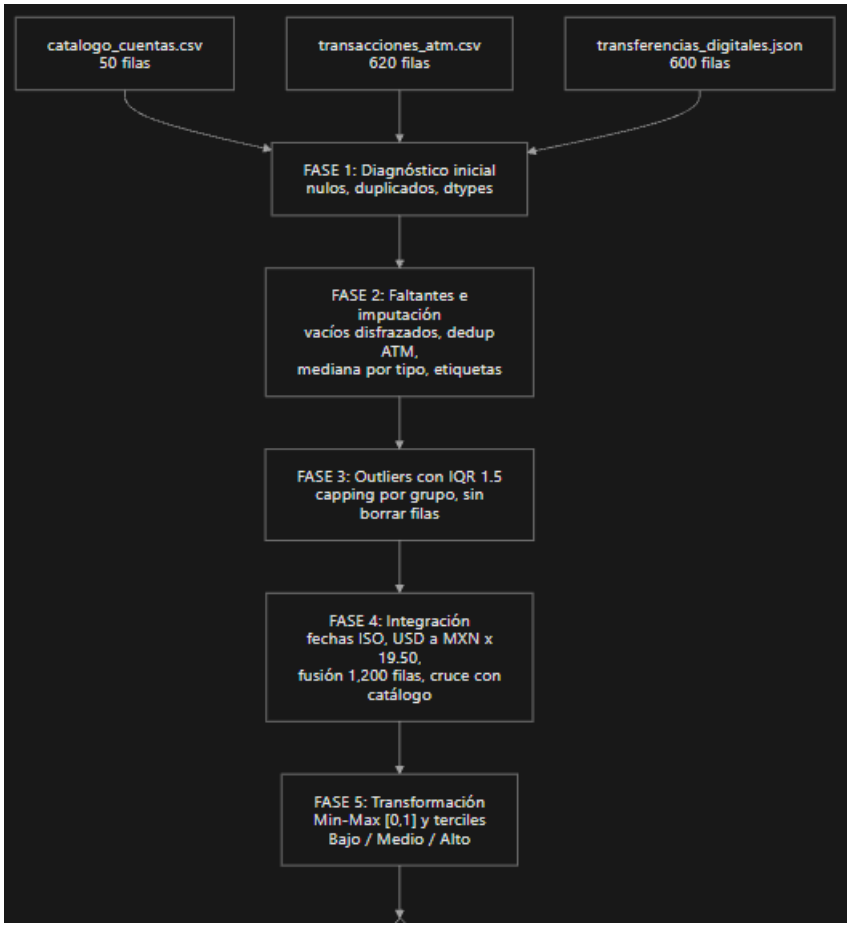
PRUEBA DE ESTRÉS:

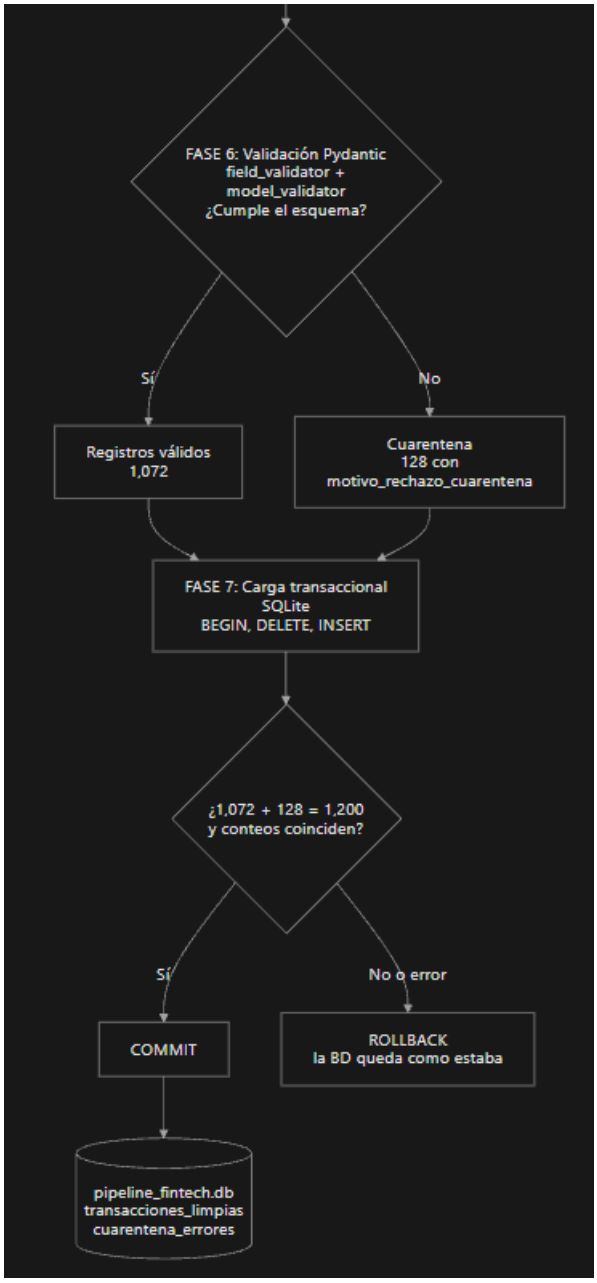
```
PRUEBAS DE ESTRÉS: INYECCIÓN DE DATOS CORRUPTOS
================================================================
                                    prueba                                    esperado
             obtenido resultado
                      Monto negativo en retiro                      VALOR_INVALIDO
LIDO + VALOR_INVALIDO        OK
                       Monto cero en un retiro                      MONTO_INVALIDO
       MONTO_INVALIDO        OK
                     Monto no numérico ('abc')                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
                                  Monto nulo                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
                        CLABE de 5 dígitos                      CLABE_INVALIDA
       CLABE_INVALIDA        OK
                           CLABE con letras                      CLABE_INVALIDA
       CLABE_INVALIDA        OK
                          Correo sin arroba                    EMAIL_MALFORMADO
     EMAIL_MALFORMADO        OK
                       Correo con doble arroba                    EMAIL_MALFORMADO
     EMAIL_MALFORMADO        OK
                           Cuenta huérfana                     CUENTA_HUERFANA
      CUENTA_HUERFANA        OK
                        Formato de cuenta roto                CUENTA_FORMATO_INVALIDO
ENTA_FORMATO_INVALIDO        OK
                      Fecha imposible (mes 13)                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
                                  Fecha nula                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
                               Hora inválida                       HORA_INVALIDA
        HORA_INVALIDA        OK
                        Estado desconocido                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
                     Moneda no soportada (EUR)                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
              Conversión de moneda inconsistente                CONVERSION_INCONSISTENTE
```

```
VERSION_INCONSISTENTE        OK
                               ATM sin id_cajero                          ATM_SIN_CAJERO
       ATM_SIN_CAJERO        OK
                            Transferencia sin CLABE                    DIGITAL_INCOMPLETO
   DIGITAL_INCOMPLETO        OK
                 ID de transacción con formato raro                       ID_INVALIDO
         ID_INVALIDO        OK
                           ID de transacción nulo                      VALOR_INVALIDO
       VALOR_INVALIDO        OK
                          Segmento inexistente                         VALOR_INVALIDO
       VALOR_INVALIDO        OK
                  Monto normalizado fuera de [0,1]                     VALOR_INVALIDO
       VALOR_INVALIDO        OK
                        Varios fallos a la vez CLABE_INVALIDA + EMAIL_MALFORMADO + CUENTA_HU... CLABE_INVALIDA + EMAIL_MALF
ORMADO + CUENTA_HU...        OK
                     Registro completamente vacío                      VALOR_INVALIDO VALOR_INVALIDO + VALOR_INVA
LIDO + VALOR_INVAL...        OK
          Concepto con acentos y símbolos (válido)                            VALIDO
               VALIDO        OK
            Cuenta con espacios alrededor (válido)                        VALIDO
               VALIDO        OK
                      Correo 'ANONIMO' (válido)                           VALIDO
               VALIDO        OK
Lote mixto (corruptos + 20 buenos) sin detenerse          23 válidos / 24 cuarentena                    23 vá
lidos / 24 cuarentena        OK
                   BD: carga normal de 5 registros                  COMMIT, 5 filas
      COMMIT, 5 filas        OK
        BD: llave duplicada en medio de la carga          ROLLBACK, 5 filas intactas
    ROLLBACK, 5 filas        OK
      BD: monto negativo viola restricción CHECK          ROLLBACK, 5 filas intactas
    ROLLBACK, 5 filas        OK
       BD: recarga del mismo lote (idempotencia)       COMMIT, 5 filas (sin duplicar)
      COMMIT, 5 filas        OK

Pruebas superadas: 32 de 32
El pipeline soporta datos corruptos sin excepciones no controladas.
Reporte guardado: reportes/pruebas_estres.csv
```

DIAGRAMA:


catalogo_cuentas.csv
50 filas
transacciones_atm.csv
620 filas
transferencias_digitales.json
600 filas
FASE 1: Diagnóstico inicial
nulos, duplicados, dtypes
FASE 2: Faltantes e imputación
vacíos disfrazados, dedup ATM,
mediana por tipo, etiquetas
FASE 3: Outliers con IQR 1.5
capping por grupo, sin borrar filas
FASE 4: Integración
fechas ISO, USD a MXN x 19.50,
fusión 1,200 filas, cruce con catálogo
FASE 5: Transformación
Min-Max [0,1] y terciles
Bajo / Medio / Alto



En conclusión:

La implementación exitosa del pipeline ETL robusto demostró que un flujo de ingeniería de datos moderno no solo debe buscar el procesamiento ideal de registros, sino garantizar resiliencia operacional total ante la ingesta de datos altamente ruidosos e inconsistentes. Gracias al principio de segregación con zona de cuarentena y la validación estricta a través de Pydantic, se logró procesar la totalidad del lote sin caídas del sistema, asegurando que únicamente los registros que cumplen con la calidad e integridad referencial lleguen a la base de datos de producción.

Reflexión

El valor principal alcanzado en esta práctica radica en el cambio de paradigma de "limpiar para no perder datos" a "validar para proteger la integridad del negocio". La combinación del filtrado estadístico, la homogenización de variables y el aislamiento mediante la zona de

cuarentena evitó la contaminación de la base de datos relacional, ofreciendo auditoría completa y trazabilidad sobre cada fila rechazada.